

A Revolução dos Agentes: Por Que o Modelo Não Basta & Anatomia de um Harness: O Corpo Que Carrega o Cérebro — Um Recorte de Harness Engineering — Do Modelo ao Sistema Autônomo Confiável

Heverton Eduardo Peres

RESUMO

A adoção de agentes autônomos de inteligência artificial na engenharia de software exige uma camada de engenharia que os modelos de linguagem, isoladamente, não fornecem. Este artigo analisa a revolução dos agentes e a anatomia do harness como artefato de engenharia, por meio de pesquisa qualitativa e bibliográfica sobre fontes institucionais, acadêmicas e de segurança publicadas entre 2022 e 2026. Os resultados revelam um modelo de cinco camadas — âncora de testes, guardrails, gestão de contexto, loop de execução e observabilidade — consistente entre as fontes analisadas, e demonstram que a confiabilidade de um sistema agêntico reside no harness, e não no modelo. Conclui-se que o test harness da engenharia de software fornece o arcabouço metodológico para a verificação de agentes e que o safety harness é componente estrutural para mitigar riscos de segurança documentados.

Palavras-chave: Harness engineering; agentes autônomos; guardrails; sistemas agênticos; engenharia de software.

ABSTRACT

The adoption of autonomous artificial intelligence agents in software engineering requires an engineering layer that language models, in isolation, do not provide. This article analyzes the agent revolution and the anatomy of the harness as an engineering artifact, through qualitative and bibliographic research on institutional, academic, and security sources published between 2022 and 2026. The results reveal a five-layer model — test anchor, guardrails, context management, execution loop, and observability — consistent across the analyzed sources, and demonstrate that the reliability of an agentic system resides in the harness, not in the model. It concludes that the software engineering test harness provides the methodological framework for agent verification and that the safety harness is a structural component to mitigate documented security risks.

Keywords: Harness engineering; autonomous agents; guardrails; agentic systems; software engineering.

1 INTRODUÇÃO

1.1 Contextualização do Problema

Entre 2024 e 2026, a engenharia de software atravessa uma mudança estrutural: modelos de linguagem de grande porte (LLMs) deixam de operar apenas como assistentes de autocomplete e passam a atuar como agentes autônomos capazes de planejar, executar e testar tarefas completas do ciclo de engenharia. A OpenAI documentou a transição para um “mundo agêntico” no qual a unidade fundamental de trabalho deixa de ser a chamada única ao modelo e passa a ser a execução orientada a tarefas, com o harness — a camada de engenharia que envolve o agente — assumindo o papel central de controle (OPENAI, 2026). Essa mudança é corroborada por dados de adoção: a LangChain reporta que 57% das organizações pesquisadas já possuem agentes em produção e que 89% priorizam observabilidade como requisito de operação (LANGCHAIN, 2026).

O problema de pesquisa decorre de uma lacuna conceitual: a difusão de ferramentas agênticas (Claude Code, Codex, Cursor) ocorre sem que a arquitetura interna que sustenta a autonomia desses sistemas seja amplamente compreendida por quem os adota. A distinção entre “ter um LLM” e “ter um agente confiável” é estrutural, não incidental: sem a camada de controle, a saída do modelo passa no teste de plausibilidade, mas falha em produção (BÖCKELER, 2026). A literatura emergente propõe tratar o harness como objeto de engenharia de primeira classe — uma coleção de práticas que inclui testes determinísticos, guardrails, gestão de contexto e observabilidade (TRIVEDI, 2026).

1.2 Objetivos

O objetivo geral deste artigo é analisar a revolução dos agentes e a anatomia do harness como artefato de engenharia, respondendo à questão: por que o modelo de linguagem, isoladamente, é insuficiente para garantir um sistema agêntico confiável? Os objetivos específicos são: (a) descrever a transição paradigmática do autocomplete para o agente; (b) detalhar as camadas do harness — âncora de testes, guardrails, corpo de contexto e trilha de observabilidade; (c) apresentar a herança do test harness da engenharia de software; e (d) discutir o papel do safety harness na prevenção de falhas de segurança.

1.3 Justificativa

A justificativa é dupla. Em termos práticos, a Gartner projeta que mais de 40% dos projetos de IA agêntica serão cancelados até 2027 por falta de retorno claro, e que 40% dos aplicativos empresariais contarão com agentes específicos de tarefa até 2026 — o que evidencia a urgência de critérios objetivos de engenharia para agentes (GARTNER, 2025). Em termos teóricos, o framework de “código como harness” propõe sistemas agênticos executáveis, verificáveis e com estado — uma agenda de pesquisa que ancora este trabalho (NING et al., 2026). O recorte adota o livro Harness Engineering — Do Modelo ao Sistema Autônomo Confiável como fonte primária, sintetizando seus quatro primeiros capítulos.

1.4 Delimitação

O estudo delimita-se à análise conceitual e arquitetural do harness, com foco em agentes de codificação e automação de engenharia. Não abrange a comparação empírica entre modelos de linguagem específicos, nem a avaliação de benchmarks de desempenho de agentes, que pertencem a trabalhos futuros.

2 METODOLOGIA

2.1 Natureza da Pesquisa

A pesquisa é de natureza qualitativa, exploratória e bibliográfica, com procedimento de análise de conteúdo sobre fontes primárias e secundárias publicadas entre 2022 e 2026. O corpus analisado inclui documentação oficial de ferramentas de agentes, artigos de engenharia de harness, relatórios institucionais de mercado e publicações de segurança de sistemas agênticos.

2.2 Coleta de Dados

A coleta seguiu três eixos complementares. O primeiro eixo compreende fontes institucionais: a documentação da OpenAI sobre harness engineering (OPENAI, 2026), o blog da LangChain sobre a anatomia do harness de agentes (TRIVEDY, 2026) e a análise da Databricks sobre o conceito de AI agent harness (DATABRICKS, 2026). O segundo eixo abrange a literatura acadêmica: o framework ReAct de raciocínio e ação (YAO et al., 2022), o benchmark SWE-bench para resolução de issues reais do GitHub (JIM et al., 2023), o SWE-Bench+ como extensão do benchmark (ALEITHAN et al., 2024) e a proposta de código como harness (NING et al., 2026). O terceiro eixo cobre segurança: o Top 10 da OWASP para aplicações de LLM (OWASP, 2025), a análise de riscos do Model Context Protocol (RED HAT, 2025) e as vulnerabilidades documentadas em agentes de codificação (UTESVSKY, 2025).

2.3 Critérios de Inclusão

Foram incluídas fontes que (a) tratam diretamente de arquitetura de agentes, harness, guardrails ou segurança de sistemas agênticos; (b) foram publicadas por organizações reconhecidas ou em veículos com revisão; e (c) possuem URL verificável. Fontes exclusivamente comerciais sem conteúdo técnico foram descartadas.

2.4 Procedimento de Análise

A análise estruturou-se em três etapas. Na primeira, o material coletado foi organizado por tema em um dossiê de pesquisa com hierarquia de fontes (primárias A, secundárias B e terciárias C). Na segunda, os conceitos foram mapeados para as cinco camadas do harness: âncora (testes determinísticos), capacete (guardrails), corpo (gestão de contexto), motor (loop de execução) e trilha (observabilidade). Na terceira, procedeu-se à síntese comparativa entre as abordagens documentadas, seguindo o método ACAD de contextualização, referencial teórico, análise e síntese parcial (NING et al., 2026; HU, 2026).

2.5 Limitações

A pesquisa limita-se à análise documental; não foram conduzidos experimentos controlados com agentes reais. A rápida evolução do campo implica que parte das fontes de 2025 e 2026 pode se tornar obsoleta em curto prazo, o que é mitigado pela triangulação entre fontes de naturezas distintas.

3 RESULTADOS E DISCUSSÃO

3.1 A Insuficiência do Modelo Isolado

A análise documental confirma que o modelo de linguagem, isoladamente, é insuficiente para a operação agêntica confiável. A OpenAI argumenta que o harness é o determinante da qualidade do resultado: o mesmo modelo, dentro de harnesses diferentes, produz resultados com qualidade diferente (OPENAI, 2026). Essa tese é corroborada pelo benchmark SWE-bench, que demonstrou que sistemas que combinam raciocínio e ação superam abordagens que usam apenas um dos modos (JIM et al., 2023). A explicação é arquitetural: o modelo propõe ações, mas quem executa é o harness — e é na execução que o sistema encontra o mundo real, não determinístico (BÖCKELER, 2026; HU, 2026).

3.2 A Anatomia do Harness em Cinco Camadas

A síntese das fontes revelou consistência na descrição de cinco camadas do harness, corroborada por múltiplos autores independentes (TRIVEDY, 2026; DATABRICKS, 2026; NING et al., 2026):

1. **Âncora (testes determinísticos)**: casos de teste que definem o comportamento esperado do agente e bloqueiam regressões antes da execução em produção. A herança vem do test harness da engenharia de software, que há décadas automatiza a verificação de comportamento.
2. **Capacete (guardrails)**: políticas automáticas que classificam ações como permitidas, controladas ou sensíveis, bloqueando as fora de escopo. A OWASP inclui o controle inadequado de ações entre os principais riscos de aplicações de LLM (OWASP, 2025).
3. **Corpo (gestão de contexto)**: o contexto do agente é um recurso finito que precisa ser gerenciado — selecionar o que entra, o que sai e o que é resumido a cada iteração (NING et al., 2026).
4. **Motor (loop de execução)**: o ciclo ReAct de raciocínio, ação e observação, com política de retentativa e escalação para humano (YAO et al., 2022).
5. **Trilha (observabilidade)**: registro estruturado de cada passo — ação, observação, custo e decisão — que permite auditoria e diagnóstico (LANGCHAIN, 2026).

3.3 A Herança do Test Harness

A análise revelou que o harness de agentes é, em grande medida, uma extensão do test harness clássico da engenharia de software. A diferença fundamental é o objeto sob teste: em vez de funções com entradas e saídas determinísticas, o objeto é um agente cujo comportamento é probabilístico. Isso exige testes de contrato — entrada canônica, saída verificável, efeitos colaterais esperados e comportamento de erro — em vez de simples testes de igualdade (NING et al., 2026). A literatura de qualidade de software reforça que o teste é o que torna o agente auditável: sem âncora determinística, o agente “funciona” até o dia em que erra em silêncio (BÖCKELER, 2026).

3.4 O Safety Harness e a Segurança

A discussão de segurança ocupa posição central na literatura. A OWASP destaca a injeção de prompts e a confiança excessiva em saídas do modelo entre os riscos mais críticos (OWASP, 2025). O Model Context Protocol, adotado como padrão para conectar agentes a ferramentas, apresenta riscos documentados de servidores não confiáveis e clientes confusos (RED HAT, 2025). A pesquisa de segurança demonstrou vulnerabilidades reais em agentes de codificação, incluindo a enganação dos prompts de aprovação humana (UTESVSKY, 2025) e o envenenamento de ferramentas MCP. Esses achados sustentam a tese de que o safety harness — a camada que impede a queda — não é opcional, mas componente estrutural da arquitetura.

3.5 Implicações Práticas

As implicações práticas derivam diretamente dos achados. Em primeiro lugar, organizações que adotam agentes devem tratar o harness como produto, com fila de melhorias e métricas, e não como tarefa pontual (LANGCHAIN, 2026). Em segundo lugar, a classificação de ações em zonas (segura, controlada, sensível) deve ser declarada nas ferramentas, antes da execução, e não decidida na conversa — separando a intenção do modelo da declaração do engenheiro (UTESVSKY, 2025; HU, 2026). Em terceiro lugar, a observabilidade deve ser tratada como requisito de primeira classe: 89% das organizações que operam agentes em produção priorizam essa camada (LANGCHAIN, 2026).

4 CONCLUSÃO

4.1 Síntese dos Achados

Este artigo respondeu à questão de pesquisa — por que o modelo de linguagem, isoladamente, é insuficiente para um sistema agêntico confiável — demonstrando que a confiabilidade reside no harness, não no modelo. A revolução dos agentes é, na prática, a revolução da engenharia de harness: a OpenAI documenta que a qualidade do resultado é determinada pela camada de engenharia que envolve o agente (OPENAI, 2026), e a anatomia em cinco camadas — âncora, capacete, corpo, motor e trilha — emergiu de forma consistente nas fontes analisadas (TRIVEDY, 2026; DATABRICKS, 2026; NING et al., 2026).

A herança do test harness da engenharia de software fornece o arcabouço metodológico: testes de contrato determinísticos substituem a avaliação intuitiva do comportamento do agente (NING et al., 2026). O safety harness adiciona a dimensão de segurança, endereçando riscos documentados como injeção de prompts, servidores MCP não confiáveis e enganação de aprovações humanas (OWASP, 2025; RED HAT, 2025; UTSVSKY, 2025).

4.2 Contribuições

O artigo contribui com: (a) uma síntese organizada da literatura emergente de harness engineering, integrando fontes institucionais, acadêmicas e de segurança; (b) um modelo de cinco camadas que oferece vocabulário comum para equipes que operam agentes; e (c) implicações práticas acionáveis — zona declarada por ferramenta, testes de contrato e observabilidade como requisito.

4.3 Limitações e Trabalhos Futuros

As limitações decorrem da natureza documental da pesquisa. Trabalhos futuros devem: (a) conduzir experimentos controlados comparando harnesses diferentes sobre o mesmo modelo; (b) avaliar quantitativamente o impacto de cada camada na taxa de sucesso de tarefas; (c) investigar a evolução das vulnerabilidades de segurança em agentes; e (d) desenvolver frameworks de medição de custo e qualidade de harness em escala de produção, respondendo ao apelo de relatórios como o DORA para práticas de engenharia mensuráveis (DORA, 2024).

REFERÊNCIAS

AI-BOOST. *Awesome Harness Engineering*. 2026. Disponível em: <https://github.com/ai-boost/awesome-harness-engineering>. Acesso em: 09 ago. 2026.

ALEITHAN, Ali et al. *SWE-Bench+: Enhanced Coding Benchmark for LLMs*. 2024. Disponível em: <https://arxiv.org/abs/2410.06992>. Acesso em: 09 ago. 2026.

ANTHROPIC. *Introducing the Model Context Protocol*. 2024. Disponível em: <https://www.anthropic.com/news/model-context-protocol>. Acesso em: 09 ago. 2026.

BÖCKELER, Birgitta. *Harness engineering for coding agent users*. 2026. Disponível em: <https://martinfowler.com/articles/harness-engineering.html>. Acesso em: 09 ago. 2026.

DATABRICKS ENGINEERING. *What is an AI Agent Harness?* 2026. Disponível em: <https://www.databricks.com/blog/ai-harness>. Acesso em: 09 ago. 2026.

DORA. *Accelerate State of DevOps Report 2024*. 2024. Disponível em: <https://dora.dev/research/2024/dora-report/>. Acesso em: 09 ago. 2026.

EMBRACE THE RED. *MCP: Untrusted Servers and Confused Clients, Plus a Sneaky Exploit*. 2025. Disponível em: <https://embracethered.com/blog/posts/2025/model-context-protocol-security-risks-and-exploits/>. Acesso em: 09 ago. 2026.

GARTNER. 2025. *Gartner Predicts 40 Percent of Enterprise Apps Will Feature Task-Specific AI Agents by 2026*. Disponível em: <https://www.gartner.com/en/newsroom/press-releases/2025-08-26-gartner-predicts-40-percent-of-enterprise-apps-will-feature-task-specific-ai-agents-by-2026-up-from-less-than-5-percent-in-2025>. Acesso em: 09 ago. 2026.

HU, W. *Architectural Design Decisions in AI Agent Harnesses*. 2026. Disponível em: <https://arxiv.org/html/2604.18071v1>. Acesso em: 09 ago. 2026.

JIM, Carlos et al. *SWE-bench: Can Language Models Resolve Real-world GitHub Issues?* 2023. Disponível em: <https://arxiv.org/abs/2310.06770>. Acesso em: 09 ago. 2026.

LANGCHAIN. *State of Agent Engineering 2026*. 2026. Disponível em: <https://www.langchain.com/state-of-agent-engineering>. Acesso em: 09 ago. 2026.

LASSO SECURITY (OXENBERG, O.; SUISA, E.). *Claude Code Security: Protect Autonomous Coding Agents*. 2025. Disponível em: <https://www.lasso.security/blog/claude-code-security>. Acesso em: 09 ago. 2026.

NING, X. et al. *Code as Agent Harness: Toward Executable, Verifiable, and Stateful Agent Systems*. 2026. Disponível em: <https://arxiv.org/html/2605.18747v1>. Acesso em: 09 ago. 2026.

OPENAI. *Harness engineering: leveraging Codex in an agent-first world*. 2026. Disponível em: <https://openai.com/index/harness-engineering/>. Acesso em: 09 ago. 2026.

OWASP FOUNDATION. *OWASP Top 10 for Large Language Model Applications*. 2025. Disponível em: <https://owasp.org/www-project-top-10-for-large-language-model-applications/>. Acesso em: 09 ago. 2026.

RED HAT PRODUCT SECURITY (CANO GABARDA, F.). *Model Context Protocol (MCP): Understanding security risks and controls*. 2025. Disponível em: <https://www.redhat.com/en/blog/model-context-protocol-mcp-understanding-security-risks-and-controls>. Acesso em: 09 ago. 2026.

TRIVEDY, Vivek. *The Anatomy of an Agent Harness*. 2026. Disponível em: <https://www.langchain.com/blog/the-anatomy-of-an-agent-harness>. Acesso em: 09 ago. 2026.

UTESVSKY, Roy. *SymJack: The approval prompt is lying to you*. 2025. Disponível em: <https://adversa.ai/blog/the-approval-prompt-is-lying-to-you-symlink-rce-in-five-ai-coding-agents-claude-code-cursor-antigravity-copilot-grok-build/>. Acesso em: 09 ago. 2026.

WIKIPEDIA. *Model Context Protocol*. 2024. Disponível em: https://en.wikipedia.org/wiki/Model_Context_Protocol. Acesso em: 09 ago. 2026.

YAO, Shunyu et al. *ReAct: Synergizing Reasoning and Acting in Language Models*. 2022. Disponível em: <https://arxiv.org/abs/2210.03629>. Acesso em: 09 ago. 2026.