

EDITORA AGÊNTICA

Harness Engineering — Do Modelo ao Sistema Autônomo Confiável

PARA INICIANTES

Heverton Eduardo Peres

Baseado em harness-engineering

Objetivo

Introdução de impacto: o dia em que o modelo errou sozinho — e ninguém tinha um arnês. Apresenta a máxima $\text{Agente} = \text{Modelo} + \text{Harness}$ e o que o leitor será capaz de construir ao final da obra.

O caminho

- ▶ **Arnês** — capítulos 1, 2, 3, 4
- ▶ **Corda** — capítulos 5, 6, 7, 8

Fundamentos — O Equipamento Essencial

| Estágio 1 de 2

A Revolução dos Agentes: Por Que o Modelo Não Basta

Explicar por que LLMs sozinhos não produzem trabalho confiável e introduzir a equação Agente = Modelo + Harness, com o mapa do que será construído na obra

- ▶ O que um agente realmente é (modelo + arcabouço)
- ▶ Onde os sistemas sem harness quebram em produção
- ▶ O retorno medido: dados de adoção e os riscos do agente solto

```
python scripts/validar-codigo.py livros/harness-engineering --capitulo 1 --executar
```

Anatomia de um Harness: O Corpo Que Carrega o Cérebro

Dissecar as camadas do harness — ambiente de execução, ferramentas, memória, estado e loops de feedback — mostrando cada peça com exemplo concreto

- ▶ As camadas do harness e suas responsabilidades
- ▶ Ferramentas, sistema de arquivos e integração com o mundo
- ▶ Estado e memória: o que o agente lembra e o que o harness guarda

```
python scripts/validar-codigo.py livros/harness-engineering --capitulo 2 --executar
```

Test Harness: A Herança da Engenharia de Software

Apresentar o harness de teste — fixtures, execução determinística, linters e CI — como a primeira linha de verificação do trabalho do agente

- ▶ O conceito clássico de test harness e sua transposição para agentes
- ▶ Execução determinística: o que o código prova que o agente acertou
- ▶ CI e gates automatizados como rede de segurança do fluxo

```
python scripts/validar-codigo.py livros/harness-engineering --capitulo 3 --executar
```

Safety Harness e Guardrails: A Camada Que Impede a Queda

Mostrar como proteger o sistema contra ações destrutivas do agente — aprovações humanas, limites de escopo, bloqueio de tool calls e princípio do menor...

- ▶ O que os guardrails interceptam e por quê
- ▶ Approval gates e a fadiga de consentimento
- ▶ Menor privilégio, sandboxes e o blast radius controlado

```
python scripts/validar-codigo.py livros/harness-engineering --capitulo 4 --executar
```


Na Prática — Instalando o Arnês e Escalando

| Estágio 2 de 2

O Ciclo ReAct e os Loops de Execução

Construir o primeiro harness funcional: o loop Reason → Act → Observe com execução de ferramentas, tratamento de erro e iteração até o objetivo

- ▶ O loop ReAct passo a passo com código executável
- ▶ Execução de ferramentas: terminal, busca e APIs no harness
- ▶ Tratamento de erro e retry: o harness decide quando o agente tenta de novo

```
python scripts/validar-codigo.py livros/harness-engineering --capitulo 5 --executar
```

Sandboxes, Permissões e o Controle de Execução

Implementar isolamento real de execução — contêineres, permissões por escopo e políticas — para que o agente faça muito sem poder fazer qualquer coisa

- ▶ Isolamento de execução: Docker, microVMs e a intenção da sandbox
- ▶ Políticas de permissão e tokens de escopo restrito
- ▶ Trilhas de auditoria: saber exatamente o que o agente fez

```
python scripts/validar-codigo.py livros/harness-engineering --capitulo 6 --executar
```

Gestão de Contexto: Combatendo o Context Rot

Ensinar a manter o agente focado em tarefas longas — compactação, offloading de ferramentas, divulgação progressiva e o padrão do loop de longa duração

- ▶ O problema do context rot em tarefas longas
- ▶ Compactação, offloading e progressive disclosure
- ▶ Ralph Wiggum Loop: o agente revisando o próprio trabalho até satisfazer critérios

```
python scripts/validar-codigo.py livros/harness-engineering --capitulo 7 --executar
```

Harness em Produção: Observabilidade, Evals e o Engenheiro Agêntico

Fechar a obra com a operação de harnesses em escala — observabilidade, evals como testes de regressão do agente e o novo papel do engenheiro que desenha...

- ▶ Observabilidade do agente: traces, logs e métricas da execução
- ▶ Evals e LLM-as-a-judge: o teste de regressão do comportamento
- ▶ O engenheiro agêntico: desenhar ambientes e especificar intenção

```
python scripts/validar-codigo.py livros/harness-engineering --capitulo 8 --executar
```

Próximo passo

Harness Engineering — Do Modelo ao Sistema Autônomo Confiável

Quero a obra completa — [https://exemplo.com/obra?
utm_source=deck&utm_medium=slides&utm_campaign=harness-engineering](https://exemplo.com/obra?utm_source=deck&utm_medium=slides&utm_campaign=harness-engineering)