

EDITORA AGÊNTICA

As 25 Armadilhas de Harness Engineering — Do Modelo ao Sistema Autônomo Confiável

Os 25 erros que travam quem está começando em
Harness Engineering — Do Modelo ao Sistema
Autônomo Confiável

PARA INICIANTES

Heverton Eduardo Peres

Um recorte de harness-engineering

As armadilhas

São **25 erros** que aparecem com mais frequência em quem está percorrendo este caminho pela primeira vez. Cada um traz a etapa em que costuma aparecer.

1. “O modelo é tão bom que não precisa de teste”: o DORA 2024 mostrou exatamente o contrário — produtividade individual sem estabilidade de entrega é um custo escondido [9]**

Onde aparece: Etapa 1 — A Revolução dos Agentes: Por Que o Modelo Não Basta

2. Permissão ampla “só por enquanto”: tokens com escopo global e diretórios liberados são o vetor favorito de incidentes [17]**

Onde aparece: Etapa 1 — A Revolução dos Agentes: Por Que o Modelo Não Basta

3. Autonomia total sem approval gates: cancelar a confirmação humana “para acelerar” transfere o risco de erro para a escala — um erro repetido 100 vezes não é 100 vezes mais rápido, é 100 vezes mais caro [16]**

Onde aparece: Etapa 1 — A Revolução dos Agentes: Por Que o Modelo Não Basta

4. Sem observabilidade: agente que faz muito e não deixa rastro é um passivo de auditoria ambulante [12]**

Onde aparece: Etapa 1 — A Revolução dos Agentes: Por Que o Modelo Não Basta

5. Ambiente compartilhado “para simplificar”: rodar o agente com as mesmas permissões do operador transforma qualquer erro em incidente de segurança; o isolamento é a primeira linha [7][17]**

Onde aparece: Etapa 2 — Anatomia de um Harness: O Corpo Que Carrega o Cérebro

6. Ferramentas ilimitadas: cada ferramenta nova é superfície de ataque nova; comece com o mínimo e expanda sob demanda [13][14]**

Onde aparece: Etapa 2 — Anatomia de um Harness: O Corpo Que Carrega o Cérebro

7. Memória só no prompt : se o estado vive apenas na janela de contexto, uma execução interrompida perde tudo; persista o que importa [6][18]**

Onde aparece: Etapa 2 — Anatomia de um Harness: O Corpo Que Carrega o Cérebro

8. Confiar na autoavaliação do modelo : “o agente disse que completou” não é evidência; é narrativa [18]**

Onde aparece: Etapa 3 — Test Harness: A Herança da Engenharia de Software

9. Testar a elegância em vez do contrato : avaliações de “qualidade” subjetivas não substituem asserções verificáveis [2]**

Onde aparece: Etapa 3 — Test Harness: A Herança da Engenharia de Software

10. Golden tests frágeis : esperar a saída exata de um sistema probabilístico quebra o teste; teste propriedades e estruturas, não strings exatas [3]**

Onde aparece: Etapa 3 — Test Harness: A Herança da Engenharia de Software

11. Segurança no prompt : “por favor, não apague nada” não é guardrail; é sugestão [20]**

Onde aparece: Etapa 4 — Safety Harness e Guardrails: A Camada Que Impede a Queda

12. Permitir por padrão : bloquear só o que se conhece deixa o desconhecido livre; inverta para deny by default**

Onde aparece: Etapa 4 — Safety Harness e Guardrails: A Camada Que Impede a Queda

13. Approval gate sem trilha : aprovação sem registro é indecifrável depois; registre quem, o quê e quando [16]**

Onde aparece: Etapa 4 — Safety Harness e Guardrails: A Camada Que Impede a Queda

14. Chamada única “direta ao modelo” **: sem loop, sem observação, sem correção de curso — o agente é um LLM com prompt bonito [4]

Onde aparece: Etapa 5 — O Ciclo ReAct e os Loops de Execução

15. Retry infinito **: falha permanente vira gasto infinito; sempre limite + backoff [19]

Onde aparece: Etapa 5 — O Ciclo ReAct e os Loops de Execução

16. Erro tratado como dado **: registrar “503” como conteúdo da resposta faz o agente raciocinar sobre um erro como se fosse fato [5]

Onde aparece: Etapa 5 — O Ciclo ReAct e os Loops de Execução

17. Credenciais do operador **: o agente com as permissões de quem o invoca é o incidente mais previsível do harness [17]

Onde aparece: Etapa 6 — Sandboxes, Permissões e o Controle de Execução

18. Sandbox de mentira **: restringir arquivos mas liberar rede (ou vice-versa) é contenção parcial; o escopo precisa cobrir todas as dimensões [19]

Onde aparece: Etapa 6 — Sandboxes, Permissões e o Controle de Execução

19. Token global “para o agente fazer tudo” **: a conveniência de hoje é o vazamento de amanhã; escopo por tarefa [17]

Onde aparece: Etapa 6 — Sandboxes, Permissões e o Controle de Execução

20. Jogar tudo no prompt **: o antídoto para “contexto pequeno” que envenena o contexto grande; divulgue progressivamente [6]

Onde aparece: Etapa 7 — Gestão de Contexto: Combatendo o Context Rot

21. Histórico bruto infinito **: cada observação fica para sempre, e a instrução se afoga; compacte por blocos [6]

Onde aparece: Etapa 7 — Gestão de Contexto: Combatendo o Context Rot

22. Estado só na conversa : sem arquivos de progresso, uma interrupção ou um retry perde tudo; persista o estado [18]**

Onde aparece: Etapa 7 — Gestão de Contexto: Combatendo o Context Rot

23. Observabilidade depois do incidente : instrumentar a caixa preta quando ela já custou caro é o padrão mais caro do mercado; instrumento no primeiro dia [12]**

Onde aparece: Etapa 8 — Harness em Produção: Observabilidade, Evals e o Engenheiro Agêntico

24. Eval de uma vez só : medir o agente uma vez e nunca mais é tirar foto de quem precisa de exame periódico; eval é monitoramento de tendência [5]**

Onde aparece: Etapa 8 — Harness em Produção: Observabilidade, Evals e o Engenheiro Agêntico

25. LLM-as-a-judge sem calibração : o julgador tem viés; sem conferência humana periódica, o eval mede o viés do julgador [19]**

Onde aparece: Etapa 8 — Harness em Produção: Observabilidade, Evals e o Engenheiro Agêntico

Selecionamos as 25 mais frequentes, distribuídas por todas as etapas. A obra completa cataloga 40.

Próximo passo

Este material é um recorte de **Harness Engineering — Do Modelo ao Sistema Autônomo Confiável**. A obra completa traz a teoria, os exemplos comentados e as referências.

Quero a obra completa