

Avaliação, segurança e supervisão humana: a governança dos sistemas de IA autônomos

Heverton Eduardo Peres

RESUMO

Este artigo examina os três pilares da governança dos sistemas de IA autônomos — avaliação, segurança e supervisão humana — que emergiram como o gargalo estrutural da adoção, superando a capacidade dos modelos. Trata-se de um recorte investigativo documental, derivado do dossiê de pesquisa indexado para a obra IA Agêntica Desbloqueada, sem coleta primária de dados: a metodologia consiste na recuperação seletiva de blocos temáticos do dossiê-mãe e na síntese analítica de guias de avaliação, segurança e supervisão com citação autor-data (NBR 10520). Os resultados indicam que a avaliação de agentes difere da avaliação de chatbots — o objeto é o processo, não apenas a resposta final — e que a hierarquia de avaliadores, da base determinística ao topo humano, torna a avaliação sustentável em escala; que a segurança converge na defesa em profundidade, com autorização granular por ferramenta, separação estrutural entre dados e instruções e validação de saídas; e que a supervisão humana se organiza em um espectro de intervenção calibrado pela matriz de impacto e reversibilidade. Discutem-se ainda a autonomia como concessão medida, que sobe com evidência de sucesso e desce com incidentes, e a integração dos três pilares como o tripé da autonomia responsável. Conclui-se que a governança é o elemento que separa a experimentação da escala em sistemas agênticos.

Palavras-chave: Avaliação de agentes, evals, LLM-as-a-judge, segurança de IA, supervisão humana, governança de IA.

ABSTRACT

This article examines the three pillars of governance for autonomous AI systems — evaluation, security, and human oversight — which have emerged as the structural bottleneck of adoption, surpassing model capability. This is a documentary investigative excerpt, derived from the research dossier indexed for the book Unlocking Agentic AI, with no primary data collection: the methodology consists of selective retrieval of thematic blocks from the parent dossier and analytical synthesis of evaluation, security, and oversight guides with author-date citation (NBR 10520). Results indicate that agent evaluation differs from chatbot evaluation — the object is the process, not just the final response — and that the evaluator hierarchy, from deterministic base to human top, makes evaluation sustainable at scale; that security converges on defense in depth, with granular per-tool authorization, structural separation between data and instructions, and output validation; and that human oversight is organized in an intervention spectrum

calibrated by the impact and reversibility matrix. Autonomy as a measured concession, rising with evidence of success and falling with incidents, and the integration of the three pillars as the tripod of responsible autonomy, are also discussed. The article concludes that governance is the element that separates experimentation from scale in agentic systems.

Keywords: Agent evaluation, evals, LLM-as-a-judge, AI security, human oversight, AI governance.

1. Introdução

O gargalo da adoção de sistemas de IA agênticos deixou de ser a capacidade dos modelos e passou a ser a governança: avaliar, proteger e supervisionar sistemas que executam ações com consequências (MCKINSEY, 2026; VALIDMIND, 2026). Este artigo examina os três pilares dessa governança — avaliação, segurança e supervisão humana — com base em fontes primárias dos provedores e em guias de segurança do setor (ANTHROPIC, 2026; COALITION, 2026).

A motivação é prática: os relatórios de risco situam a manipulação de contexto e a dependência de saídas não verificadas entre os principais riscos dos sistemas agênticos, e a confiança é o gargalo estrutural da escala (VALIDMIND, 2026; MCKINSEY, 2026). Sem evals, segurança e supervisão, o sistema autônomo é uma caixa-preta com poder de ação — a combinação mais perigosa do campo (CERBOS, 2026).

O artigo está organizado em quatro seções: introdução, metodologia, resultados e discussão, e conclusão — cobrindo as três dimensões da governança em um arcabouço unificado. A supervisão humana é tratada como o complemento da autonomia, não a sua negação (GALILEO, 2026; MICROSOFT, 2026).

REFERÊNCIAS

ADIMULAM, A.; GUPTA, R.; KUMAR, S., 2026. *The Orchestration of Multi-Agent Systems: Architectures, Protocols, and Enterprise Adoption*. Disponível em: <https://arxiv.org/html/2601.13671v1>. Acesso em: 07 ago. 2026.

AMAZON WEB SERVICES (AWS), 2026. *Traditional agent architecture: perceive, reason, act*. AWS Prescriptive Guidance: Foundations of Agentic AI on AWS. Disponível em: <https://docs.aws.amazon.com/prescriptive-guidance/latest/agentic-ai-foundations/traditional-agents.html>. Acesso em: 07 ago. 2026.

ANTHROPIC, 2024. *Building Effective Agents*. Disponível em: <https://www.anthropic.com/engineering/building-effective-agents>. Acesso em: 07 ago. 2026.

ANTHROPIC, 2026. *Demystifying Evals for AI Agents*. Disponível em: <https://www.anthropic.com/engineering/demystifying-evals-for-ai-agents>. Acesso em: 07 ago. 2026.

BRAINTRUST, 2026. *AI Gateway Comparison: The 6 Best Ranked (2026)*. Disponível em: <https://www.braintrust.dev/articles/ai-gateway-comparison-2026>. Acesso em: 07 ago. 2026.

CERBOS, 2026. *AI Agents, the Model Context Protocol, and the Future of Authorization Guardrails*. Disponível em: <https://www.cerbos.dev/news/securing-ai-agents-model-context-protocol>. Acesso em: 07 ago. 2026.

COALITION FOR SECURE AI (CoSAI), 2026. *Securing the AI Agent Revolution: A Practical Guide to Model Context Protocol Security*. Disponível em: <https://www.coalitionforcureai.org/securing-the-ai-agent-revolution-a-practical-guide-to-mcp-security/>. Acesso em: 07 ago. 2026.

DIGITAL APPLIED, 2026. *State of AI Agents 2026: 200+ Data Points Compiled*. Disponível em: <https://www.digitalapplied.com/blog/state-of-ai-agents-2026-200-data-points>. Acesso em: 07 ago. 2026.

DORA / GOOGLE CLOUD, 2025. *DORA: State of AI-assisted Software Development 2025*. Disponível em: <https://dora.dev/dora-report-2025/>. Acesso em: 07 ago. 2026.

FIN.AI, 2026. *AI Agent ROI: Customer Support Returns*. Disponível em: <https://fin.ai/blog/ai-agent-roi-customer-support>. Acesso em: 07 ago. 2026.

GALILEO, 2026. *How to Build Human-in-the-Loop Oversight for Production AI Agents*. Disponível em: <https://galileo.ai/blog/human-in-the-loop-agent-oversight>. Acesso em: 07 ago. 2026.

GARTNER, 2025. *Gartner Predicts 40% of Enterprise Apps Will Feature Task-Specific AI Agents by 2026*. Disponível em: <https://www.gartner.com/en/newsroom/press-releases/2025-08-26-gartner-predicts-40-percent-of-enterprise-apps-will-feature-task-specific-ai-agents-by-2026-up-from-less-than-5-percent-in-2025>. Acesso em: 07 ago. 2026.

GOOGLE CLOUD, 2026. *Choose a Design Pattern for Your Agentic AI System*. Cloud Architecture Center. Disponível em: <https://docs.cloud.google.com/architecture/choose-design-pattern-agentic-ai-system>. Acesso em: 07 ago. 2026.

GUO, Taicheng; et al., 2024. *Large Language Model based Multi-Agents: A Survey of Progress and Challenges*. IJCAI. Disponível em: <https://arxiv.org/abs/2402.01680>. Acesso em: 07 ago. 2026.

HONG, Sirui; et al., 2024. *MetaGPT: Meta Programming for A Multi-Agent Collaborative Framework*. ICLR. Disponível em: <https://arxiv.org/abs/2308.00352>. Acesso em: 07 ago. 2026.

LANGCHAIN TEAM, 2025. *Context Engineering for Agents*. Disponível em: <https://www.langchain.com/blog/context-engineering-for-agents>. Acesso em: 07 ago. 2026.

LANGCHAIN, 2026. *The Best AI Agent Frameworks in 2026*. Disponível em: <https://www.langchain.com/resources/ai-agent-frameworks>. Acesso em: 07 ago. 2026.

LIU, Xiao; et al., 2025. *AgentBench: Evaluating LLMs as Agents*. ICLR. Disponível em: <https://arxiv.org/abs/2308.03688>. Acesso em: 07 ago. 2026.

MAXIM AI, 2026. *Best Enterprise LLM Gateways in 2026: A Comparative Guide*. Disponível em: <https://www.getmaxim.ai/articles/best-enterprise-llm-gateways-in-2026-a-comparative-guide/>. Acesso em: 07 ago. 2026.

MCKINSEY & COMPANY, 2026. *State of AI Trust in 2026: Shifting to the Agentic Era*. Disponível em: <https://www.mckinsey.com/capabilities/tech-and-ai/our-insights/tech-forward/state-of-ai-trust-in-2026-shifting-to-the-agentic-era>. Acesso em: 07 ago. 2026.

MICROSOFT AZURE ARCHITECTURE CENTER, 2026. *AI Agent Orchestration Patterns*. Disponível em: <https://learn.microsoft.com/en-us/azure/architecture/ai-ml/guide/ai-agent-design-patterns>. Acesso em: 07 ago. 2026.

ONEAWAY, 2026. *Best AI Sales Agents in 2026, Ranked by Autonomy*. Disponível em: <https://oneaway.io/blog/best-ai-sales-agents-in-2026-ranked-by-autonomy>. Acesso em: 07 ago. 2026.

SALESFORCE, 2026. *New Research: AI Service Agents Improve Customer Satisfaction*. Disponível em: <https://www.salesforce.com/news/stories/ai-service-agents-improve-customer-satisfaction/>. Acesso em: 07 ago. 2026.

VALIDMIND, 2026. *Top 10 AI Risk Trends for 2026*. Disponível em: <https://validmind.com/blog/10-ai-risk-trends-for-2026/>. Acesso em: 07 ago. 2026.

ZENITY, 2026. *What Is the Model Context Protocol? Full Guide*. Disponível em: <https://zenity.io/academy/model-context-protocol-explained>. Acesso em: 07 ago. 2026.