

Contents

Relatório de Sessão — Estimativa de Consumo de Tokens de um Turno Completo	1
1. Contexto	1
2. Parâmetros adotados	1
3. Estimativa por fase	2
4. Totais	2
Custo estimado (modelo da sessão)	3
5. Onde o peso morre	3
6. Redutores já ativos	3
7. Conclusão	3
8. Validação	3
9. Arquivos	3

Relatório de Sessão — Estimativa de Consumo de Tokens de um Turno Completo

- **Data:** 18-08-2026
- **Tema:** Estimativa de consumo de tokens e custo de um turno completo da Fábrica Agêntica de Publicações
- **Método:** Análise do fluxo operacional (AGENTS.md), tamanhos contratados de obra (parametros_obra.py), tamanho real dos prompts dos subagentes (.claude/agents/*.md) e dados históricos do RTK Scratchpad. Sem medição real por sessão — estimativa por fase.

1. Contexto

A fábrica produz coleções completas (livro + derivados + campanha + máquina) via orquestrador + subagentes especializados + scripts determinísticos. Pergunta do operador: quanto uma produção FULL consome de tokens?

2. Parâmetros adotados

- **Obra base:** livro tamanho M (padrão) — 8 capítulos, 200.000 caracteres (TAMANHOS em parametros_obra.py).
- **Coleção:** ~12 materiais (livro, playbook, lead magnets, decks, e-mails, derivados).
- **Ratio PT-BR:** ~3,5–4 caracteres por token → capítulo M (~25k chars) ≈ 6–7k tokens de output.
- **Retentativa média:** ~1,3× por capítulo (máx. 3 tentativas, backoff no pool-capitulos.py).
- **Modelo:** indefinido (model: inherit) — custo calculado por faixa de preço.

3. Estimativa por fase

Fase	LLM	Input	Output	Total
Pesquisa (pesquisador + arquiteto)	alto	~200k	~30k	~230k
Estratégia (drafts × 8 caps)	médio	~400k	~40k	~440k
Redação (sub-agentes × 8, c/ retentativa)	alto	~3–4M	~350k	~3,5–4,5M
Revisão técnica (revisor-tecnico)	médio	~600k–1M	~100–200k	~700k–1,2M
Compilação ABNT (merge + refs + prefácio)	médio	~300–600k	~50–100k	~350–700k
Derivados (ebooks/artigos/TCC)	médio	~500k–1M	~150–300k	~650k–1,3M
Campanha (copy dos moldes, 12 materiais)	baixo	~300–600k	~100–200k	~400–800k
Máquina de vendas (personalização)	baixo–médio	~150–300k	~50–100k	~200–400k
Playbook / LM / Deck / E-mails / mineração / auditorias / PDF	zero (determinístico)	—	—	0
Orquestração (roteador, leituras, QA)	variável	~500k–1,5M	~100–300k	~600k–1,8M

4. Totais

- **Coleção M típica: ~7–11M tokens** (input + output)
- Coleção P enxuta: ~4–5M
- G/GG ou retentativas altas: ~12–20M

Custo estimado (modelo da sessão)

Modelo	10M in + 1,5M out	BRL (câmbio 5,5)
Fallback Sonnet 4 (\$3/15) <i>US</i> 52	~R\$ 290	
DeepSeek V3 (\$0,5/2) <i>US</i> 8	~R\$ 45	
Modelo free (ex.: roteador free)	—	R\$ 0

5. Onde o peso morre

1. **Redação de capítulos** $\approx 55\text{--}60\%$ — subagente multi-turno re-envia contexto (dossiê RAG + draft + skill) a cada turno; input $\gg$ output ($\sim 10:1$).
2. **Orquestração** $\approx 15\text{--}20\%$ — pior quando o operador acompanha turno a turno.
3. **Retentativas** — cada falha re-spawna o contexto inteiro do subagente.

6. Redutores já ativos

- `pool-capitulos.py` — lote 4 + backoff exponencial limita re-spawn em paralelo.
- Stack token-economy (LeanCTX, Headroom, Cavecrew) — corta reenvio de logs/contexto.
- Fases determinísticas isentam $\sim 30\%$ do fluxo (custos LLM zero).
- RTK Scratchpad — evita re-análise de bugs já resolvidos.

7. Conclusão

Turno completo $M \approx 7\text{--}11\text{M tokens}$; custo de R\$ 45 a R\$ 290 conforme o modelo (ou R\$ 0 em modelo free). Metade do consumo é input repetido na redação de capítulos — alavanca principal de redução é o tamanho/lote do contexto dos subagentes-redator, não o modelo.

8. Validação

- Nenhum código alterado nesta sessão — apenas relatório e compilação PDF.
- Suíte de testes: não aplicável (sem mudança em código).
- Compilação PDF verificada (cabeçalho %PDF + tamanho não-zero).

9. Arquivos

- `relatorios/18-08--estimativa-consumo-tokens.md`
- `relatorios/18-08--estimativa-consumo-tokens.pdf`